

Diseño industrial óptimo con redes neuronales

Scala, S.^{a,b,*}, Lopez, R.^{a,1}

^aArtelnics, C/ del Adaja 10, 37185 Villamayor, Salamanca, España.

^bKU Leuven, Departamento de Ingeniería Química, Celestijnenlaan 200F, 3001 Lovaina, Bélgica.

To cite this article: Scala, S., Lopez, R. 2026. Optimal industrial design with neural networks. XXI Simposio CEA de Control Inteligente, Salamanca.

Resumen

Presentamos un marco de optimización sin derivadas para hallar las condiciones de operación óptimas de sistemas modelados mediante redes neuronales entrenadas con datos. El método, denominado contracción iterativa del dominio (IDC, *iterative domain contraction*), aprovecha el coste de evaluación casi nulo de la red para emplear presupuestos de muestreo masivos, y maneja de forma nativa restricciones de caja, lineales y de fórmula, así como problemas mono- y multiobjetivo. Implementado en la biblioteca de código abierto OpenNN, se ilustra con dos casos. En el primero se minimiza la fotodegradación de una mezcla fotovoltaica orgánica cuaternaria, sujeta a una restricción de simplex y a una ventana funcional donante:aceptor, obteniéndose una heterounión realista y físicamente utilizable. En el segundo se aborda el diseño bi-objetivo de un casco de velero a velocidad fija, donde la resistencia al avance y la manga del casco entran en conflicto (un casco más ancho gana estabilidad y espacio interior pero aumenta el arrastre); IDC traza un frente de Pareto denso que revela con nitidez ese compromiso y su rodilla, sobre la que se sitúa el diseño recomendado. En ambos casos los resultados son muy satisfactorios y prometedores.

Palabras clave: Optimización basada en datos, Redes neuronales, Optimización sin derivadas, Metodología de superficie de respuesta, Optimización multiobjetivo, Manejo de restricciones.

Optimal industrial design with neural networks

Abstract

We present a derivative-free framework for finding the optimal operating conditions of systems modelled by data-trained neural networks. The method, iterative domain contraction (IDC), exploits the near-zero evaluation cost of the surrogate to afford massive sampling budgets, and natively handles box, linear and formula constraints as well as single- and multi-objective problems. Implemented in the open-source library OpenNN, it is illustrated on two cases. The first minimises the photodegradation of a quaternary organic photovoltaic blend, subject to a simplex constraint and a functional donor:acceptor window, yielding a realistic, physically usable heterojunction. The second addresses the bi-objective design of a sailing-yacht hull at fixed speed, where residuary resistance and hull beam conflict (a wider hull gains stability and interior space but increases drag); IDC traces a dense Pareto front that clearly reveals this trade-off and its knee, where the recommended design lies. In both cases the results are very good and promising.

Keywords: Data-driven optimization, Neural networks, Derivative-free optimization, Response surface methodology, Multi-objective optimization, Constraint handling.

1. Introducción

El *diseño óptimo* de un proceso industrial consiste en fijar sus variables controlables de modo que se minimice un coste, se

maximice un rendimiento o se satisfagan unas especificaciones. En muchos dominios (tratamiento de aguas, metalurgia, procesos químicos, energía) la relación entre esas variables y las respuestas medibles es demasiado compleja para un modelado de

*Autor para correspondencia.

S. Scala: simone.scala@kuleuven.be, ORCID <https://orcid.org/0009-0005-6403-2815>
Attribution-NonCommercial-ShareAlike 4.0 International (CC BY-NC-SA 4.0)

¹R. Lopez: robertolopez@artelnics.com, ORCID <https://orcid.org/0000-0003-3729-1465>

primeros principios, pero se aproxima bien a partir de datos. La *cadena de optimización basada en datos* consta de tres etapas: (1) recogida de datos del sistema físico, (2) entrenamiento de una red neuronal sustituta $f: \mathbb{R}^n \rightarrow \mathbb{R}^m$, y (3) optimización de las entradas sobre la red entrenada. Las dos primeras etapas están bien cubiertas por el aprendizaje automático actual; la tercera, la *optimización de la respuesta* (Myers et al., 2016; Derringer and Suich, 1980), es el objeto de este trabajo. Enlaza directamente con el control inteligente: las condiciones óptimas no son sólo un diseño estático, sino las *consignas* (*setpoints*) que la capa de control debe alcanzar y mantener.

La red sustituta cambia el régimen de cómputo: a diferencia de un simulador físico o de una superficie de respuesta polinómica, su evaluación es prácticamente gratuita (10^4 – 10^6 evaluaciones por segundo), lo que habilita presupuestos de muestreo masivo. El reto deja de ser el coste de evaluación y pasa a ser el *manejo de las restricciones*. La vía habitual, que incrusta la red entrenada como conjunto de restricciones en un resolutor matemático (Ceccon et al., 2022; Parker et al., 2024), ofrece garantías de optimalidad, pero escala con dificultad y exige linealizar o relajar la red. En el extremo opuesto, los metaheurísticos (algoritmos genéticos, CMA-ES) muestrean con libertad pero *no* garantizan factibilidad: ante una restricción lineal de igualdad, como el *simplex* $\sum_i x_i = 1$ de una mezcla, el conjunto factible es un volumen de medida nula y la práctica totalidad de los puntos muestreados o recombinados lo violan, de modo que el optimizador malgasta su presupuesto en candidatos inviables.

Proponemos atacar ese reto con la *contracción iterativa del dominio* (IDC). IDC comparte el esquema “muestrear, seleccionar y contraer” de la búsqueda aleatoria acelerada (Appel et al., 2003), pero lo combina con un *operador de reparación afín* que proyecta cada muestra sobre las restricciones lineales *antes* de evaluar la red, logrando factibilidad por construcción sin rechazo. Así aprovecha el muestreo masivo que permite el sustituto neuronal y maneja de forma nativa variables mixtas y restricciones de caja, lineales y de fórmula. El método está implementado en la biblioteca de código abierto OpenNN (Artelnics, 2026), que también provee el entrenamiento de la red. El presente trabajo es una contribución breve, en español y orientada a la aplicación: el desarrollo metodológico completo de IDC y su batería de validación se recogen en un manuscrito de revista actualmente en revisión (Scala et al., 2026), que aquí no se reproduce; este artículo lo ilustra sobre dos casos industriales nuevos (uno mono-objetivo con una restricción de *simplex* y otro bi-objetivo de diseño mecánico), sin solapamiento de publicación.

2. Contracción iterativa del dominio

Sea f una red neuronal entrenada con p variables de entrada (continuas, binarias o categóricas) y q de salida. A cada variable se le puede asignar una *condición*: una restricción ($v \bowtie \beta$, con $\bowtie \in \{=, \leq, \geq, \in [l, u]\}$) o una designación como *objetivo* a minimizar o maximizar. Además se admiten *restricciones de fórmula* $g(\mathbf{x}, \mathbf{y}) \bowtie \beta$, afines o no lineales, sobre entradas y/o salidas. El problema general es

$$\max_{\mathbf{x} \in \mathcal{X}} (s_1 o_1(\mathbf{x}), \dots, s_k o_k(\mathbf{x})), \quad (1)$$

donde o_j extrae el j -ésimo objetivo de la entrada o de la salida $\mathbf{y} = f(\mathbf{x})$, $s_j = \pm 1$ fija el sentido y $\mathcal{X}$ es el conjunto factible. Con $k = 1$ la solución es un punto óptimo; con $k \geq 2$, el conjunto de Pareto.

El algoritmo (Figura 1) parte de un dominio hiperrectangular $\mathcal{D}^{(0)}$ derivado del rango de los datos de entrenamiento y acotado por las condiciones. En cada iteración t :

1. se generan N entradas aleatorias en $\mathcal{D}^{(t)}$;
2. las restricciones *afines de entrada* se reparan algebraicamente sobre la muestra (operador de reparación afín), de modo que cada punto satisface la restricción lineal sin rechazo;
3. se evalúa la red y se descartan los puntos que violan los límites de salida o las fórmulas;
4. los objetivos se normalizan a $[0, 1]$ y se selecciona el subconjunto élite más cercano al *punto utópico* $\hat{\mathbf{u}}^* = \mathbf{1}$ en distancia euclídea;
5. el dominio se contrae alrededor del mejor punto: para cada coordenada continua h ,

$$l_h^{(t+1)} = \max(x_h^* - \frac{\gamma}{2} \Delta_h^{(t)}, l_h^{(t)}), \quad u_h^{(t+1)} = \min(x_h^* + \frac{\gamma}{2} \Delta_h^{(t)}, u_h^{(t)}), \quad (2)$$

con $\Delta_h^{(t)} = u_h^{(t)} - l_h^{(t)}$ y factor de zoom $\gamma \in (0, 1)$.

El bucle termina cuando el cambio relativo del objetivo cae por debajo de una tolerancia o se agota el presupuesto de iteraciones. La reparación afín garantiza factibilidad por construcción frente a restricciones lineales, lo que ningún operador genético o de muestreo gaussiano asegura. En el caso multiobjetivo (Figura 2) se mantiene un frente de Pareto que se refina localmente en torno a los puntos no dominados, monitorizado por dos métricas geométricas de calidad (hueco interno y cercanía a la frontera).

Operador de reparación afín. Una restricción lineal sobre las entradas se escribe $g(\mathbf{x}) = \mathbf{a}^\top \mathbf{x} + c \bowtie \beta$. Dada una muestra $\mathbf{x}$ con valor actual $v = \mathbf{a}^\top \mathbf{x} + c$, se fija el objetivo $\bar{g}$ (para una igualdad, $\bar{g} = \beta$; para un intervalo $[l, u]$, $\bar{g}$ es el extremo violado, o no hay reparación si ya es factible) y el residuo $e = v - \bar{g}$. La corrección de mínima norma que lo anula es la proyección ortogonal sobre el hiperplano de la restricción,

$$\Delta x_i = -e \frac{a_i}{\|\mathbf{a}\|^2}, \quad (3)$$

o bien, en variante *proporcional*, $\Delta x_i = -e x_i / (\mathbf{a}^\top \mathbf{x})$, que preserva las razones entre variables. Tras aplicarla se recorta cada variable a su caja, $x_i \leftarrow \max(l_i, \min(u_i, x_i + \Delta x_i))$; las que *saturan* se congelan y su residuo no absorbido se redistribuye entre las activas, repitiendo la proyección a lo sumo n veces. Para el *simplex* ($\mathbf{a} = \mathbf{1}$, $c = 0$, $\beta = 1$) la ecuación (3) reparte el exceso por igual, $\Delta x_i = -e/n$, y, en ausencia de saturación, restaura $\sum_i x_i = 1$ en una sola pasada. Como la reparación actúa *antes* de evaluar la red, cada punto entra factible y no se desperdicia presupuesto en rechazos.

Hiperparámetros y convergencia. Sólo cuatro hiperparámetros gobiernan IDC (Tabla 1). El factor de zoom γ regula el compromiso exploración/refinamiento: valores altos contraen el dominio despacio (más robusto, más costoso) y valores bajos, depri- (riesgo de óptimo local). Con la configuración de la Tabla 1

el caso mono-objetivo converge de forma muy estable: sobre 21 semillas aleatorias el óptimo es idéntico hasta la sexta cifra significativa (degradación = $0,05572 \pm 3 \times 10^{-7}$) y el 100 % de las corridas devuelve un punto factible. La combinación de reparación afín y muestreo masivo elimina así, en la práctica, la dependencia de la semilla.

Tabla 1: Hiperparámetros de IDC empleados en ambos casos.

Hiperparámetro	Valor
Muestras por iteración N	2000
Factor de zoom γ	0,85
Tolerancia relativa de parada	10^{-6}
Iteraciones máximas	20 (SO) / 12 (MO)

3. Caso mono-objetivo: fotodegradación de una mezcla OPV

Problema físico. Las células solares orgánicas de heterounión en volumen se fabrican mezclando dos donantes y dos aceptores; la fracción de cada componente determina la morfología de la película y, con ella, su estabilidad bajo iluminación. El problema está en que estas mezclas se degradan con la luz, lo que acorta la vida útil del panel; hallar la composición más fotoestable es por ello decisivo para la viabilidad comercial de esta tecnología. Se usa el conjunto `photo_wf3` de la *suite* Olympus (Häse et al., 2021), con 1040 mezclas cuaternarias medidas: dos donantes (WF3, el polímero de banda ancha PBQ-QF, y P3HT) y dos aceptores (PCBM, fullereno, y oIDTBR, no fullereno) (Langner et al., 2020).

Formalización y modelo. Las cuatro fracciones másicas $\mathbf{x} = (x_1, x_2, x_3, x_4)$ deben minimizar la fotodegradación medida $y(\mathbf{x})$ sujetas, primero, al *simplex*

$$x_1 + x_2 + x_3 + x_4 = 1, \quad x_i \geq 0, \quad (4)$$

una igualdad afín que reduce el espacio factible a un volumen de medida nula dentro del cubo $[0, 1]^4$. Ahora bien, minimizar sólo la fotoestabilidad degenera: como el donante es la principal vía de degradación, el óptimo tiende a una mezcla *sin donante*, que no es una célula solar. Un dispositivo de heterounión necesita sendas redes percolantes de donante y de aceptor y, en operación, cada fotón absorbido transfiere un electrón del donante al aceptor en la interfaz, de modo que el balance estequiométrico de carga es $\approx 1:1$. Imponemos por ello una *ventana funcional donante:aceptor* sobre la fracción total de donante (WF3 + P3HT):

$$0,4 \leq x_1 + x_2 \leq 0,6, \quad (5)$$

esto es, una relación donante:aceptor entre 2:3 y 3:2. La campaña original (Langner et al., 2020) sólo imponía el *simplex*; esta ventana es una elección de modelado nuestra para garantizar un dispositivo realista, y constituye una restricción lineal adicional que IDC maneja de forma nativa junto al *simplex*. Como sustituto $y(\mathbf{x})$ se entrena con OpenNN una red con una capa oculta de 8 neuronas, que alcanza $R^2 = 0,77$ sobre los 1040 datos (Figura 3a); el interés del caso reside sobre todo en el manejo simultáneo de las dos restricciones lineales.




Figura 3: Bondad de ajuste de los sustitutos de OpenNN. (a) Fotodegradación de la mezcla OPV (8 neuronas): $R^2 = 0,77$ sobre 1040 mezclas (0,80 en test). (b) Resistencia residual del velero (4 neuronas): $R^2 = 0,995$ sobre 308 medidas (0,99 en test).

Diseño óptimo. Ejecutamos IDC sobre la red entrenada con los 1040 datos, con un presupuesto de 40 000 evaluaciones. Gracias al operador de reparación afín, el punto devuelto satisface a la vez el *simplex* y la ventana donante:aceptor (*factibilidad por construcción*). La mezcla óptima hallada (Tabla 2) es una heterounión realista (donante WF3 $\approx 0,41$ y aceptor fullereno PCBM $\approx 0,59$, relación donante:aceptor $\approx 1:1,4$) con una fotodegradación de 0,056 y el 100 % de factibilidad. El coste de exigir un dispositivo funcional es modesto: la degradación sólo sube de $\approx 0,03$ (óptimo degenerado sin donante) a 0,056, a cambio de una solución físicamente utilizable.

 Tabla 2: Caso `photo_wf3`: diseño óptimo hallado por IDC.

Variable	Valor óptimo
WF3 (donante)	0.409
P3HT (donante)	0.000
PCBM (aceptor)	0.591
oIDTBR (aceptor)	0.000
Donante total / aceptor total	0.41 / 0.59
Relación donante:aceptor	1 : 1,44
Fotodegradación	0.0557
Factibilidad (<i>simplex</i> + D:A)	100 %

4. Caso multiobjetivo: diseño de un casco de velero

Problema físico. El conjunto *Yacht Hydrodynamics* (serie sistemática de Delft) relaciona cinco coeficientes geométricos del casco y el número de Froude (velocidad) con la resistencia residual por unidad de peso (Ortigosa et al., 2007), el mismo problema con el que se gestó OpenNN. El problema de diseño reside en un conflicto entre objetivos: a una velocidad de crucero fija, un casco más ancho (menor relación eslora/manga) ofrece más estabilidad y espacio de cubierta y bodega, pero a costa de una mayor resistencia y, por tanto, de un mayor consumo. Acertar con ese equilibrio es una decisión central del diseño naval.

Formalización y modelo. A partir de 308 medidas reales de canal de ensayos, y fijando el número de Froude a la *media del conjunto* (0,2875) como restricción de igualdad, se busca *minimizar la resistencia residual* (salida de la red) y *maximizar la manga*, esto es, minimizar la relación eslora/manga L/B (una entrada), con los cuatro coeficientes restantes del casco libres




Figura 1: Estrategia mono-objetivo de IDC (IDC-SO): a partir del dominio inicial, el lazo genera puntos factibles (muestreo aleatorio, filtrado de entradas y salidas por restricciones, evaluación del modelo), extrae los mejores y contrae el dominio hasta cumplir el criterio de parada.

dentro del envolvente de Delft; en el sustituto, L/B y la resistencia correlacionan negativamente ($-0,61$). El selector *growing neurons* de OpenNN encuentra una red compacta de 4 neuronas que alcanza $R^2 = 0,995$ sobre todo el conjunto y $R^2 = 0,99$ en el de test (Figura 3b), confirmando que una arquitectura pequeña y bien dimensionada generaliza sin dificultad.

Diseño óptimo. Ejecutamos IDC con un presupuesto de 40 000 evaluaciones. El muestreo masivo dirigido al punto utópico puebla densamente el frente con unos 270 cascos no dominados (Tabla 3). Normalizamos cada objetivo respecto a su propio rango sobre el frente, de modo que éste recorre la caja unidad de esquina a esquina; el área bajo la curva es el hipervolumen normalizado, 0,59 (Figura 4). Normalizar en cambio respecto al rango del conjunto de datos completo elevaría el hipervolumen a $\approx 0,98$, pero comprimiría el frente en una franja estrecha y ocultaría la forma del compromiso. Éste es claro: al ensanchar el casco (reducir L/B de 3,64 a 2,73) la resistencia residual mínima sube de $\approx 0,5$ a $\approx 2,3$, con una rodilla bien definida en la región central. El *punto recomendado*, el más cercano al punto utópico (punto azul en la Figura 4, Tabla 3), cae precisamente en esa rodilla: un casco de manga intermedia ($L/B \approx 3,06$) con una resistencia residual de $\approx 1,4$, que equilibra ambos objetivos.




Figura 4: Frente de Pareto de IDC (resistencia frente a manga, esto es la relación eslora/manga L/B , a Froude fijo). Cada eje se normaliza respecto al propio rango del frente (1 = mejor); el área sombreada es el hipervolumen normalizado ($= 0,59$). Se aprecian el compromiso entre ambos objetivos y la rodilla en la que se sitúa el punto recomendado (azul), unido al punto utópico.

Tabla 3: Resultado de IDC en el caso *yacht* bi-objetivo: $|\mathcal{P}|$ (tamaño del frente), HV normalizado en $[0, 1]$ (1 = ideal) y el punto recomendado (más cercano al utópico).

Métrica	Valor
HV normalizado	0.594
Tamaño del frente $ \mathcal{P} $	272
<i>Punto recomendado (más cercano al utópico)</i>	
Resistencia residual	1.389
Relación eslora/manga L/B	3.060

Coste computacional. Todas las ejecuciones se realizaron en un portátil de gama media (Intel Core i7-8550U a 1,8 GHz,




Figura 2: Estrategia multiobjetivo de IDC (IDC-MO): se inicializa el frente de Pareto global (una corrida tipo IDC-SO) y, para cada punto del frente, se generan puntos factibles, se recopilan los candidatos, se extraen los dominantes y se calculan métricas de calidad hasta la parada.

32 GB de RAM), en un solo hilo y sin GPU. El caso mono-objetivo (40 000 evaluaciones) tarda $\approx 0,066$ s de media sobre las 21 semillas, esto es una tasa de unas 6×10^5 evaluaciones por segundo, coherente con el coste casi nulo del sustituto neuronal. El caso bi-objetivo, que refina un frente creciente de cientos de cascos, se completa en segundos a pocos minutos sobre el mismo equipo según el tamaño final del frente. Estos tiempos confirman que el muestreo masivo de IDC es viable en hardware modesto, lo que lo hace apto para su uso interactivo en entornos industriales.

5. Conclusiones

La contracción iterativa del dominio cierra la cadena dato $\rightarrow$ red $\rightarrow$ optimización con un algoritmo simple, pocos hiperparámetros y manejo nativo de variables mixtas y restricciones. Su reparación afín garantiza factibilidad por construcción frente a restricciones lineales (decisiva en el caso del simplex) y su muestreo masivo, habilitado por el coste casi nulo del sustituto, produce frentes de Pareto densos. Como trabajo en curso se extiende la validación a problemas industriales de mayor escala, en particular al tratamiento de aguas residuales, con objetivos de coste frente a calidad del efluente. El código y los datos de reproducción de este trabajo están disponibles en <https://github.com/Siscanalysis/idc-sci2026>, y la biblioteca OpenNN, que implementa IDC, en <https://github.com/Artelnics/opennn>.

Agradecimientos

Financiado por la Unión Europea (Acuerdo de Subvención Marie Skłodowska-Curie n.º 101169541, NEUTEN). Las opi-

niones y los puntos de vista expresados son únicamente los de los autores y no reflejan necesariamente los de la Unión Europea ni los de la Agencia Ejecutiva Europea de Investigación (REA). Ni la Unión Europea ni la autoridad otorgante pueden ser consideradas responsables de ellos.

Referencias

- Appel, M. J., Labarre, R., Radulović, D., 2003. On accelerated random search. *SIAM Journal on Optimization* 14 (3), 708–731.
- Artelnics, 2026. OpenNN: An open-source neural networks library for machine learning. <https://github.com/Artelnics/opennn>, rama de desarrollo (dev).
- Ceccon, F., Jalving, J., Haddad, J., Thebelt, A., Tsay, C., Laird, C. D., Misener, R., 2022. OMLT: Optimization and machine learning toolkit. *Journal of Machine Learning Research* 23 (349), 1–8.
- Derringer, G., Suich, R., 1980. Simultaneous optimization of several response variables. *Journal of Quality Technology* 12 (4), 214–219.
- Häse, F., Aldeghi, M., Hickman, R. J., Roch, L. M., Aspuru-Guzik, A., 2021. Olympus: a benchmarking framework for noisy optimization and experiment planning. *Machine Learning: Science and Technology* 2 (3), 035021.
- Langner, S., Häse, F., Perea, J. D., Stubhan, T., Hauch, J., Roch, L. M., Heumüller, T., Aspuru-Guzik, A., Brabec, C. J., 2020. Beyond ternary OPV: High-throughput experimentation and self-driving laboratories optimize multi-component systems. *Advanced Materials* 32 (14), 1907801.
- Myers, R. H., Montgomery, D. C., Anderson-Cook, C. M., 2016. *Response Surface Methodology: Process and Product Optimization Using Designed Experiments*, 4th Edition. Wiley.
- Ortigosa, I., Lopez, R., García, J., 2007. A neural networks approach to residuary resistance of sailing yachts prediction. In: *Proceedings of the International Conference on Marine Engineering (MARINE 2007)*.
- Parker, R. B., Dowson, O., LoGiudice, N., García, M., Bent, R., 2024. Formulations and scalability of neural network surrogates in nonlinear optimization problems. *arXiv preprint arXiv:2412.11403*.
- Scala, S., Lopez, R., Assumpção, J. M., Dewil, R., 2026. Neural network response optimization via iterative domain contraction. *Manuscrito en revisión*, AIMS Applied Computing and Sciences in Engineering (ACSE).